

Санкт-Петербургский государственный университет
Факультет Прикладной математики - Процессов управления

Кафедра Технологии программирования

Коробков Никита Александрович
Выпускная квалификационная работа бакалавра

Метод межъязыковой адаптации диалоговых систем

Направление 01.03.02
Прикладная математика и информатика

Научный руководитель:
старший преподаватель Мишенин А.Н.

Санкт-Петербург
2019

Оглавление

Введение	2
Постановка задачи	5
Обзор литературы	7
1. Обработка данных	10
2. Алгоритм	13
2.1. Статистический анализ	13
2.1.1. Метод	13
2.2. Модели Векторов Предложений	15
2.2.1. FastText - average	15
2.2.2. fastText - взвешенное среднее	16
2.2.3. ELMo - среднее	17
2.2.4. Universal Sentence Encoder	17
2.3. Линейное преобразование	18
3. Результаты	20
3.1. Статистический Анализ	20
3.2. Модели Векторов Предложений	20
3.3. Линейное Преобразование	21
Выводы	22
Заключение	23
Список литературы	24

Введение

В последние годы все больше внимания уделяется решению различных задач с применением машинного обучения и нейронных сетей. Одним из наиболее интересных направлений в области применения современных нейросетевых методов являются диалоговые системы.

Диалоговая система это набор программ и алгоритмов позволяющих человеку вести диалог с программой в манере свойственной человеческой. Иногда диалоговые системы называют разговорным искусственным интеллектом или "чат-ботом".

Задача построения подобных программ является актуальной для промышленной области потому, что решение задач пользователей путем диалога с агентом поддержки всегда было и будет оставаться наиболее простым и эффективным методом. Так как вербальное общение наиболее естественный для человека способ коммуникации. Построение хорошей и надежной диалоговой системы заменяющей работников колл центра позволило бы существенно сократить затраты ресурсов.

Диалоговые системы можно разделить на системы общего назначения и задачеориентированные. Чем более узкую задачу призвана решать система, тем проще она может быть устроена. В самом тривиальном случае система может просто возвращать заранее известный ответ. Например текущее время.

Мы хотели бы построить систему решающую более общую задачу. Для этого в нужно сначала выяснить детально чего именно хочет пользователь (задать вопрос и получить ответ). В самой тривиальной реализации этот сценарий может выглядеть как простой выбор задачи из списка. С применением такого подхода в промышленности можно столкнуться уже сегодня. Позвонив в банк и авиакомпанию можно

часто услышать робота, который предложит нажать разные кнопки в зависимости от цели звонка ("Для проверки баланса нажмите 1, для уточнения статуса заявки нажмите 2" и т.п.). Этот подход хорош тем, что не требует от системы никакой интеллектуальности и работает очень надежно. Однако занимает много пользовательского времени и зачастую нервирует. В идеальном случае мы хотели бы получив запрос в виде предложения на натуральном языке, например "Какая погода сейчас на улице?" сразу распознать намерение пользователя.

Это одна из подзадач в построении диалоговых систем, на которой хотелось бы сконцентрировать наше внимание в этой работе. Данная задача является довольно актуальной и стоит уже давно. Так что для ее решения было предложено множество методик. Подобнее они будут рассмотрены в разделе "Обзор литературы". Большинство методов ориентированно на работу с английским языком. В основном потому, что для английского собранно наиболее большое количество данных. Кроме того английский просто считается языком по умолчанию в научной среде.

В то время как для английского языка достигнуты внушительные результаты, ситуация с другими языками обстоит несколько иначе. Представленные модели в большинстве своем обучены на колоссальном объеме размеченных данных. Таких данных не существует для более редких языков. По этому простое перенесение достигнутых результатов путем обучения идентичной модели на другом языке не представляется возможным. Тем не менее, почти для всех мировых языков существуют полные словари. Пользуясь общими знаниями о связи двух языков (словари, параллельные тексты) можно обобщить знания одной модели на другой язык не используя размеченных данных для второго языка совсем (либо используя совсем немного). Данный подход в литературе носит название Transfer Learning. Целью данной работы будет построение модели для извлечения намерения

из предложения на **шведском** языке при помощи переноса знаний накопленных обученной на английском языке модели. Выработанную методику можно будет использовать для построения моделей приблизительно такой же точности для любого другого языка для которого существует словарь перевода слов на английский.

Постановка задачи

Пусть существует множество команд на английском языке E и конечное множество намерений K

$$K = \{k_1, k_2, \dots, k_n\}$$

Каждой команде из E однозначно соответствует элемент множества K . Соответствие обозначим J_e

$$J_e : E \rightarrow K$$

Тренировочные данные состоят из множеств E, K и соответствия J_e . При этом существует так же функции-переводчик T , которая каждой команде на английском языке ставит в соответствие команду на шведском языке. Множество команд на шведском языке обозначим S

$$T : E \rightarrow S$$

Целью данной работы будет получение функции $J_s : S \rightarrow K$ сопоставляющей любой команде на шведском языке ее намерение. При этом должны выполняться два условия.

1. Намерение должно совпадать с намерением перевода шведской команды на английский язык.

$$\forall s \in S \quad J_s(s) = J_e(T^{-1}(s)) \quad (1)$$

$$\forall e \in E \quad J_s(T(e)) = J_e(e) \quad (2)$$

2. Функция J_s не должна зависеть от функции T

Второе условие является определяющим для данной задачи. Если бы мы могли использовать функцию T в J_s то можно было бы просто определить J_s как в (1) и остановиться на этом. Но это невозможно,

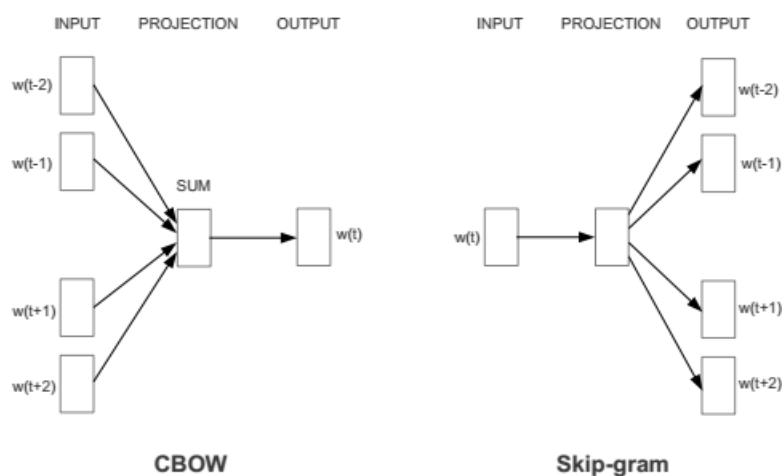
так как перевод (вычисление T^{-1}) это слишком дорогостоящая операция. Мы бы хотели получить функцию которая была бы достаточно легковычисляемой для использования в мобильных приложениях. Поэтому вместо прямого перевода команды со шведского языка на английский и последующего применения существующих алгоритмов мы постараемся выделить какие-то ключевые атрибуты команды на шведском языке и использовать их для распознавания намерения.

В силу требования 2 мы едва ли сможем удовлетворить требование 1 полностью. Вместо этого попытаемся построить систему, которая на тренировочных данных сможет максимально часто предсказывать намерения пользователя правильно. В качестве метрики качества предсказаний будем использовать долю команд в тестовой выборке, по которой система приняла правильное решение.

Обзор литературы

Задача построения диалоговых систем лежит в области автоматического анализа текстовых данных. Одним из главных вопросов применения нейронных сетей в данной области является эффективное представление слов в памяти компьютера. При анализе текстов мы бы хотели заменять слова на вектора как-то отражающие семантический смысл слова. Наиболее распространенный метод получения векторов слов описан в работах [13]. В данном подходе обучающий текстовый корпус просматривается окном ширины $2h + 1$ слов, и для каждого окна однослойная нейронная сеть предсказывает центральное слово окна $w(t)$ по окружающим $w(t + i)$, $i \in [-h, h]$ или наоборот. Эти архитектуры называются Continuous Bag-of-words и Skipgram соответственно. Минимизируя ошибку предсказания, нейронная сеть строит проекцию слов в векторное пространство заранее определенной размерности. При достижении заданной точности предсказания или определенного числа эпох, алгоритм генерирует словарь с векторными представлениями для слов из обучающего корпуса.

Рис. 1. Архитектуры нейронных сетей, представленные в [13] для окна ширины $h = 5$



Данный подход позволяет получить вектора обладающие свойством семантической близости. Мы можем надеяться что слова обладающие схожим смыслом будут находится рядом в построенном векторном пространстве. После того как методы описанные в [13] показали свою эффективность в ряде задач обработки текстов [14]. Было разработано и предложено несколько похожих методов построения векторов слов [16], [15]

В данный момент большинство методик обработки естественного языка так или иначе использует вектора слов.

В нашей работе мы использовали дополненную реализацию оригинального word to vec "fasttext" [2]. В отличие от оригинальной архитектуры этот подход помимо слов контекста использует части слов для обучения, что позволяет предсказывать вектора слов для слов отсутствующих в тренировочной коллекции.

Для работы с последовательностями слов (предложениями) часто применяются рекуррентные нейронные сети описанные в статьях [17] [10]. Воизбежание проблемы затухающих градиентов при обучении, используют LSTM архитектуру [9].

В статье Attention is all you need [18] группа исследователей из Google описывает принципиально новый подход к обработке последовательной текстовой информации и в частности к переводам. Вместо классической архитектуры рекуррентных нейронных сетей с использованием LSTM или GRU модулей автор использует так называемый механизм внимания, Который позволяет более качественно представлять информацию содержащуюся в предложениях на этапе кодирования. Такую сеть так же называют "Трансформер" из за гибкости внутренней структуры, позволяющей получать разную информацию о кодируемом предложении в зависимости от запроса. Многие современные автоматические переводчики пользуются этой технологией. В нашей работе мы пользовались готовой системой автоматическо-

го перевода от Яндекс. Примерное описание механизмов работы их переводчика доступно в статье [19]

Идея трансформер сетей развивается в статье [6]. Авторы предлагают тренировать многослойную модель из трансформер модулей на задаче определения связности предложений и предсказания пропущенного слова. Полученная модель показывает исключительные результаты после дообучения на ряде конкретных задач.

Задача предсказания намерения из фиксированного множества может быть сформулированная как задача классификации предложений. Интересный подход к этой задаче с использованием сверточных сетей предложен в статье [11].

1. Обработка данных

В нашей работе в качестве тренировочных и тестовых данных мы использовали датасет собранный компанией SNIPS [5]. Данные включают в себя более 13000 запросов пользователей на английском языке. Каждый запрос относится к одной из семи категорий по намерению пользователя.

Представленные намерения:

- Get weather (Посмотреть погоду - 2000 записей)
- Play music (Включить музыку - 2000 записей)
- Book restaurant (Забронировать ресторан - 1973 записей)
- Search creative work (Посик произведений - 1954 записей)
- Add to playlist (Добавить в плейлист - 1942 записей)
- Rate book (Поставить оценку книге - 1956 записей)
- Search movie schedule (Расписание сеансов кино - 1959 записей)

Данные предоставлены компанией SNIPS по лицензии Creative Commons Zero v1.0 Universal и доступны для скачивания по ссылке <https://github.com/snipsco/nlu-benchmark>

Таблица 1. Примеры запросов из датасета SNIPS

Категория	Пример
Get weather	What is the forecast at 12 am in Sudan.
Play music	Play some 1954 songs on my Itunes.
Book restaurant	What is the forecast at 12 am in Sudan.
Search creative work	Find me the Lace and Whiskey soundtrack.
Add to playlist	Add this artist to spring music.
Rate book	give this textbook a 5 out of 6 rating.
Search movie schedule	Where is Road to the Stage playing.

Для подготовки тренировочных и тестовых данных на шведском языке мы использовали API сервиса Яндекс Переводчик ¹.

Перед использованием для обучения моделей текст проходил предобработку. Она состояла из нескольких этапов.

- 1) Приведение всех букв к нижнему регистру
- 2) Замена всех пробельных символов на пробелы
- 3) Снятие всех ударений, умлаутов и подобных знаков. Удаление всех не ascii символов
- 4) Раскрытие всех сокращений (Например "You're -> you are")
- 5) Удаление всех специальных символов при помощи регулярных выражений
- 6) Удаление множественных пробелов

¹<https://translate.yandex.ru/developers>

После предобработки датасет содержал 13784 пары предложений. Медианная длина запроса на английском языке – 8 слов. Самые короткие запросы состоят из двух слов, например: "play pop". Самый длинный из 33 слов. Всего датасет включает 11282 уникальных английских слова, каждое слово в среднем встречается 10 раз.

Медианная длина запроса на шведском языке также 8 слов. Уникальных слов на 14% больше чем в английском – 12852. Весь датасет включает по 119529 и 115914 слов в английском и шведском языках соответственно.

2. Алгоритм

2.1. Статистический анализ

Для лучшего понимания структуры данных и с целью развития интуиции для отбора моделей, в ходе работы был произведен небольшой статистический анализ набора данных. Некоторые рассмотренные ниже модели опираются на слово как на единицу информации и рассматривают предложения как неупорядоченные наборы слов т.н. "мешки слов". Было решено сравнить отдельные слова по некоторой величине отражающей ценность этого слова для классификации предложений.

2.1.1. Метод

Для описания методики вычисления полезности слова для классификации введем некоторые обозначения. Пусть язык E содержит N_e уникальных слов. $\{w_1, \dots, w_{N_e}\}$ - всевозможные уникальные слова языка E . Слова встречаются в предложениях, всего есть D предложений. $\{s_1, \dots, s_D\}$. Кроме того каждое предложение относится к тому или иному классу $k \in K = \{k_1, \dots, k_n\}$. Рассмотрим два индикатора. Индикатор принадлежности классу:

$$I_k(s, k) = \begin{cases} 1 & \text{если предложение } s \text{ принадлежит классу } k \\ 0 & \text{если предложение } s \text{ не принадлежит классу } k \end{cases}$$

И индикатор вхождения слова в предложение:

$$I_s(s, w) = \begin{cases} 1 & \text{если предложение } s \text{ содержит слово } w \\ 0 & \text{если предложение } s \text{ не содержит слово } w \end{cases}$$

Тогда введем следующие обозначения: $c_{i,j}$ – количество раз ко-

торое слово w_i встретилось в предложениях класса k_j .

$$c_{i,j} = \sum_{0 < t < D} I_k(s_t, k_j) * I_s(s_t, w_i)$$

$p_{i,j}$ - доля предложений с меткой k_j среди всех предложений со словом w_i .

$$p_{i,j} = \frac{c_{i,j}}{\sum_{0 < t < D} I_s(s_t, w_i)}$$

$l_{i,j}$ = доля предложений в которых встречается слово w_i среди предложений с меткой k_j .

$$l_{i,j} = \frac{c_{i,j}}{\sum_{0 < t < D} I_k(s_t, k_j)}$$

Используя введенные обозначения запишем выражение для вычисления статистики $U(w_i)$ отражающей условную полезность слова w_i для задачи классификации.

$$U(w_i) = \sum_{0 < j < n} [(p_{i,j} - \frac{1}{n})^2 * l_{i,j}] * \frac{n}{n-1}$$

Значение величины $U(w_i)$ стремится к нулю, при приближении распределения слова w_i по классам к случайному.

$$p_{i,j} \rightarrow \frac{1}{n} \forall j \in \{1, \dots, n\} \implies u_i \rightarrow 0$$

При этом, чем более вырождено распределение слова по классам и чем больше предложений класса содержат это слово, тем больше будет значение метрики. Если слово w_i встречается исключительно в предложениях класса k_j и при этом каждое предложение класса k_j содержит это слово, то значение метрики достигнет единицы. Это будет означать, что одно это слово позволяет безошибочно указать на принадлежность всех предложений содержащих его к конкретному классу k_j .

2.2. Модели Векторов Предложений

Как уже говорилось ранее, задачи обработки языка подразумевают необходимость представления слов и предложений на естественном языке в каком-либо удобном для обработки виде. Как правило это вектора. В нашей работе мы будем активно использовать представление предложений как векторов, то есть функцию J_s будем искать в виде:

$$J_s(s) = J_s(V_s(s))$$

где V_s - преобразование предложения на шведском языке к вектору.

Для того чтобы изучать перенос знаний модели для английского языка на другой, нужно сначала подобрать хорошую архитектуру, работающую в одном домене.

В нашей работе мы пользовались несколькими разработанными методиками для представления предложений в виде векторов в некотором пространстве.

2.2.1. FastText - average

Для самой простой методики построения векторов предложений мы опирались на готовую модель от Facebook – fastText [8]. Это реализация алгоритма CBOW для получения векторов слов с некоторыми дополнениями. Для обучения модели в качестве входных параметров Fasttext использует не только слова контекста, как в классической реализации [13], но и символьные n-граммы. То есть все подслова определенных длин. Итоговый вектор слова получается как сумма таких n-грамм. Эта методика была описана командой Facebook AI Research в статье [2] и показала свою эффективность в задачах поиска похожих слов и аналогий. Наличие информации о подсловах при обучении модели позволяет использовать ее для получения векторов слов для слов ранее не вставившихся в словаре.

В ходе работы мы сами не обучали модель, а использовали опубликованные в открытом доступе предобученные вектора fastText. Эти данные распространяются по лицензии CC BY-SA 3.0, найти их можно по адресу <https://fasttext.cc/docs/en/crawl-vectors.html>. При обучении векторов использовалась архитектура CBOW с n-граммами длины 5, размером окна 5 и размером вектора 300. Для обучения использовались тексты с Wikipedia и других открытых источников.

Для получения векторов предложений мы брали среднее значение всех векторов слов полученных из модели. Такой подход не учитывает порядок и взаимное расположение слов, зато работает очень быстро.

2.2.2. fastText - взвешенное среднее

При усреднении всех векторов слов для получения вектора предложения информация содержащаяся в отдельных словах зашумляется. Многие слова не несут полезной для классификации смысловой нагрузки. Хотелось бы отличать такие слова и не использовать их для усреднения.

Мы протестировали еще одну методику получения векторов предложений на основе fastText. Для получения вектора предложения мы вычисляли взвешенное среднее всех слов входящих в него. В качестве веса использовалась предложенная нами в предыдущей главе величина полезности слова для классификации $U(w)$.

$$V_s(s) = \frac{\sum_{w_i \in s} V_{fastText}(w_i) * U(w_i)}{\sum_{w_i \in s} U(w_i)}$$

При заранее вычисленных величинах $U(w_i) \forall i \in [1 \dots N]$ такой подход так же работает быстро, но позволяет снизить количество шума в векторе и тем самым поднять качество классификации.

2.2.3. ELMo - среднее

В качестве альтернативы fastText мы рассмотрели другую модель для получения векторов предложений – ELMo (Embeddings from Language Models)[16]. Эта методика основана на использовании внутренних слоев обученной двунаправленной языковой LSTM сети для предсказания слов. На первом слое двунаправленной сети подаются вектора слов полученные из сверточной сети на символах. Затем следуют два biLSTM слоя. Итоговый вектор слова получается как линейная комбинация выходных значений на предыдущих трех слоях.

В нашей работе, мы, так же как и в случае с fastText, не обучали модель самостоятельно, а использовали предобученные. Данные использованные в работе [4] [7] доступны на сайте <https://github.com/HIT-SCIR/ELMoForManyLangs#downloads>. Данная модель была обучена на корпусе в 20 миллионов слов случайно набранном из Wikipedia и других открытых источников. Размерность получаемого вектора слова – 1024.

Данная модель, естественным образом использует информацию о расположении слов при вычислении векторов, так как включает в себя двунаправленные LSTM модули. Однако вычисления занимают несколько больше времени, в сравнении с fastText.

Как и в случае с fastText векторами, в качестве вектора предложения мы брали среднее значение векторов всех его слов.

2.2.4. Universal Sentence Encoder

USE [3] – наиболее современная из трех рассмотренных технологий предложенная в апреле 2018 года исследовательской группой Google. Построение векторов предложений предложенное в статье основывается на использовании глубокой нейронной сети для преобра-

зования отдельных векторов слов к вектору предложения. Данная сеть обучается на различных задачах обработки языка, что позволяет достичь существенных результатов в разных областях. Однако получение векторов требует существенных вычислительных затрат.

В нашей работе мы использовали предобученную модель реализованную с использованием фреймворка TensorFlow [1] размещенную по адресу <https://tfhub.dev/google/universal-sentence-encoder/2>. Модель распространяется по лицензии CC BY 3.0. Размерность получаемых векторов предложений – 512.

Для оценки качества векторов предложений в контексте задачи распознавания намерения пользователя мы обучали однослойную нейронную сеть предсказывать вероятности классов. Ошибка сети считалась с помощью отрицательной логарифмической функции правдоподобия. Для изменения весов использовался метод Adam [12]. Точность полученного классификатора измерялась как процент правильно предсказанных меток для тестовой выборки с использованием кросс-валидации для обоих языков.

2.3. Линейное преобразование

Допустим у нас есть модель J_e , которая по вектору запроса на английском языке хорошо предсказывает намерение K . Тогда для решения задачи предсказания намерения для второго языка, достаточно построить преобразование векторов запроса со второго языка на английский и затем воспользоваться J_e . Заметим, что такое преобразование не будет являться переводом, так как восстановление предложения по его вектору практически невозможно.

В качестве первого тестируемого метода поиска преобразования мы выбрали простую линейную модель. Функция $L(V_s(s))$ искалась в виде $L(V_s(s)) = V_s(s)A$. Для нахождения матрицы преобразования A решалась линейная система уравнений на тренировочном подмноже-

стве данных.

$$V_s A = V_e$$

Где V_s и V_e – матрицы векторов предложений размерности N_v на N_{train} . N_v – Длина вектора предложения в представлении V , N_{train} – количество примеров обучающей выборки

Так как N_{train} как правило сильно больше N_v система получается переопределенной. Под решением мы понимаем такую матрицу A , которая минимизирует Евклидово расстояние между столбцами в правой и левой частях выражения. Для нахождения матрицы A используется метод наименьших квадратов.

В нашем эксперименте, для выбора предсказанной метки предложения, мы находили расстояние от образа вектора $V_s(s_i)$ до всех векторов $V_e(e_j)$ из тестовой выборки кроме непосредственного перевода s_i и в качестве предсказанного класса брали класс предложения e_j , расстояние до вектора которого было минимальным.

$$J_s(s_i) = J_e(\arg \min_{\substack{j=1 \dots N_{train} \\ j \neq i}} (\|L(V_s(s_i)) - V_e(e_j)\|^2))$$

3. Результаты

3.1. Статистический Анализ

Рис. 2. Топ-20 слов по "полезности для классификации" в Английском и Шведском языках

#	word	label	u	mplp	mpll	#	word	label	u	mplp	mpll
1	add	AddToPlaylist	0.686	0.996	0.809	1	lagg	AddToPlaylist	0.58	0.995	0.683
2	play	PlayMusic	0.629	0.924	0.883	2	boka	BookRestaurant	0.508	0.966	0.642
3	playlist	AddToPlaylist	0.464	0.931	0.64	3	spellista	AddToPlaylist	0.441	0.942	0.592
4	rate	RateBook	0.436	0.997	0.512	4	spela	PlayMusic	0.415	0.782	0.867
5	weather	GetWeather	0.376	0.999	0.44	5	till	AddToPlaylist	0.388	0.775	0.829
6	movie	SearchScreeningEvent	0.36	0.917	0.514	6	bord	BookRestaurant	0.306	0.994	0.361
7	restaurant	BookRestaurant	0.313	0.993	0.372	7	restaurang	BookRestaurant	0.302	0.993	0.358
8	book	BookRestaurant	0.28	0.764	0.622	8	filmer	SearchScreeningEvent	0.277	0.995	0.327
9	be	GetWeather	0.256	0.909	0.373	9	kommer	GetWeather	0.27	0.915	0.388
10	will	GetWeather	0.248	0.924	0.347	10	det	GetWeather	0.252	0.716	0.653
11	points	RateBook	0.244	0.998	0.286	11	poang	RateBook	0.244	1.0	0.284
12	forecast	GetWeather	0.243	1.0	0.283	12	stjarnor	RateBook	0.243	0.986	0.293
13	out	RateBook	0.24	0.915	0.345	13	vader	GetWeather	0.239	0.998	0.28
14	stars	RateBook	0.234	0.976	0.288	14	betygsatt	RateBook	0.213	1.0	0.249
15	playing	SearchScreeningEvent	0.225	0.978	0.276	15	min	AddToPlaylist	0.209	0.766	0.459
16	table	BookRestaurant	0.223	0.992	0.265	16	musik	PlayMusic	0.176	0.912	0.255
17	my	AddToPlaylist	0.222	0.741	0.527	17	film	SearchScreeningEvent	0.161	0.909	0.235
18	give	RateBook	0.208	0.873	0.333	18	priser	RateBook	0.161	0.992	0.192
19	it	GetWeather	0.207	0.896	0.311	19	bli	GetWeather	0.146	0.997	0.172
20	movies	SearchScreeningEvent	0.201	0.992	0.239	20	biograf	SearchScreeningEvent	0.143	0.997	0.168

3.2. Модели Векторов Предложений

Таблица 2. Точность классификации для моделей основанных на векторах предложений для разных языков

Модель	Английский	Шведский
FastText-avg	91.9%	88.3%
FastText-uw-avg	96.2%	94.2%
ELMo-avg	97.7%	96.0%
USE	96.8%	—

3.3. Линейное Преобразование

В ходе работы было протестированно 6 различных пар представлений предложений на Английском и Шведском языках. Для каждой пары мы вычисляли матрицу преобразования векторов с Шведского языка на Английский, и пользовались ей для предсказания класса шведского предложения.

В таблице представлен средний процент правильно предсказанных меток после кросс-валидации в зависимости от используемых векторов предложений для разных языков.

Таблица 3. Точность модели с линейным преобразованием векторов предложений

Шведский	Английский	Точность
FastText-avg	ELMo-avg	86.2%
FastText-avg	USE	89.6%
FastText-uw-avg	ELMo-avg	88.8%
FastText-uw-avg	USE	91.2%
ELMo-avg	ELMo-avg	89.1%
ELMo-avg	USE	91.5%

Выводы

Выводы

Заклучение

Заклучение

Список литературы

- [1] Martín Abadi, Paul Barham, Jianmin Chen, Zhifeng Chen, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Geoffrey Irving, Michael Isard, Manjunath Kudlur, Josh Levenberg, Rajat Monga, Sherry Moore, Derek G. Murray, Benoit Steiner, Paul Tucker, Vijay Vasudevan, Pete Warden, Martin Wicke, Yuan Yu, and Xiaoqiang Zheng. Tensorflow: A system for large-scale machine learning. In *12th USENIX Symposium on Operating Systems Design and Implementation (OSDI 16)*, pages 265–283, Savannah, GA, 2016. USENIX Association.
- [2] Piotr Bojanowski, Edouard Grave, Armand Joulin, and Tomas Mikolov. Enriching word vectors with subword information. *arXiv preprint arXiv:1607.04606*, 2016.
- [3] Daniel Cer, Yinfei Yang, Sheng-yi Kong, Nan Hua, Nicole Limtiaco, Rhomni St. John, Noah Constant, Mario Guajardo-Cespedes, Steve Yuan, Chris Tar, Yun-Hsuan Sung, Brian Stroe, and Ray Kurzweil. Universal sentence encoder. *CoRR*, abs/1803.11175, 2018.
- [4] Wanxiang Che, Yijia Liu, Yuxuan Wang, Bo Zheng, and Ting Liu. Towards better UD parsing: Deep contextualized word embeddings, ensemble, and treebank concatenation. In *Proceedings of the CoNLL 2018 Shared Task: Multilingual Parsing from Raw Text to Universal Dependencies*, pages 55–64, Brussels, Belgium, October 2018. Association for Computational Linguistics.
- [5] Alice Coucke, Alaa Saade, Adrien Ball, Théodore Bluche, Alexandre Caulier, David Leroy, Clément Doumouro, Thibault Gisselbrecht, Francesco Caltagirone, Thibaut Lavril, Maël Primet, and Joseph Dureau. Snips voice platform: an embedded spoken language

- understanding system for private-by-design voice interfaces. *CoRR*, abs/1805.10190, 2018.
- [6] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: pre-training of deep bidirectional transformers for language understanding. *CoRR*, abs/1810.04805, 2018.
 - [7] Murhaf Fares, Andrey Kutuzov, Stephan Oepen, and Erik Velldal. Word vectors, reuse, and replicability: Towards a community repository of large-text resources. In *Proceedings of the 21st Nordic Conference on Computational Linguistics*, pages 271–276, Gothenburg, Sweden, May 2017. Association for Computational Linguistics.
 - [8] Edouard Grave, Piotr Bojanowski, Prakhar Gupta, Armand Joulin, and Tomas Mikolov. Learning word vectors for 157 languages. In *Proceedings of the International Conference on Language Resources and Evaluation (LREC 2018)*, 2018.
 - [9] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Comput.*, 9(8):1735–1780, November 1997.
 - [10] Andrej Karpathy, Justin Johnson, and Fei-Fei Li. Visualizing and understanding recurrent networks. *CoRR*, abs/1506.02078, 2015.
 - [11] Yoon Kim. Convolutional neural networks for sentence classification. *CoRR*, abs/1408.5882, 2014.
 - [12] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings*, 2015.

- [13] T. Mikolov, K. Chen, G. Corrado, and J. Dean. Efficient Estimation of Word Representations in Vector Space. *ArXiv e-prints*, January 2013.
- [14] T. Mikolov, Q. V. Le, and I. Sutskever. Exploiting Similarities among Languages for Machine Translation. *ArXiv e-prints*, September 2013.
- [15] Jeffrey Pennington, Richard Socher, and Christopher D. Manning. Glove: Global vectors for word representation. In *In EMNLP*, 2014.
- [16] Matthew E. Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, and Luke Zettlemoyer. Deep contextualized word representations. In *Proc. of NAACL*, 2018.
- [17] Alex Sherstinsky. Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network. *CoRR*, abs/1808.03314, 2018.
- [18] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems 30*, pages 5998–6008. Curran Associates, Inc., 2017.
- [19] Yandex. Технологии - Машинный перевод, 2019. Дата обращения - 4 апреля 2019.